

# 逻辑回归模型

对于一个二元分类问题，我们可以使用最小二乘法的回归模型来做：

$$y = w_0 + \sum_{j=1}^d w_j x_j + u$$
$$= \tilde{\mathbf{W}}^T \tilde{\mathbf{X}}$$


如果基于上述模型预测的 $y$ 值来作为样本属于某个类别的概率，那么预测的值会超出0到1的范围。为了解决预测概率超出0到1范围的问题，我们可以使用logit变换来解决上述问题：

$$\log\left(\frac{p}{1-p}\right) = w_0 + \sum_{j=1}^d w_j x_j + u$$
$$= \tilde{\mathbf{W}}^T \tilde{\mathbf{X}}$$

上式实际上就是将 $y$ 替换为 $\log(p/(1-p))$ ，其中

$p$ 是事件 $y$ 发生的概率， $p/(1-p)$ 称为机率比或优势比。因此，只要通过求解上式的 $p$ ，将它表示成 $y$ 的表达式，就可以将回归模型转化为输出为0到1范围的逻辑回归模型。逻辑回归模型的定义如下：

$$p = \frac{1}{1 + e^{-w_0 - \sum_{j=1}^d w_j x_j}} = \frac{e^{w_0 + \sum_{j=1}^d w_j x_j}}{1 + e^{w_0 + \sum_{j=1}^d w_j x_j}}$$
$$= \frac{1}{1 + e^{-\tilde{\mathbf{W}}^T \tilde{\mathbf{X}}}} = \frac{e^{\tilde{\mathbf{W}}^T \tilde{\mathbf{X}}}}{1 + e^{\tilde{\mathbf{W}}^T \tilde{\mathbf{X}}}}$$



- 如果  $w_0 + \sum_{j=1}^d w_j x_j = 0$  , 那么  $p = 0.5$
- 当  $w_0 + \sum_{j=1}^d w_j x_j$  很大时,  $p$  趋近于 1
- 当  $w_0 + \sum_{j=1}^d w_j x_j$  很小时,  $p$  趋近于 0

**PLA ?**

对于最小二乘法回归模型，使用了最小二乘的公式，直接得到了最终的模型。

对于逻辑回归模型，可以使用极大似然估计，配合梯度下降法，计算出最终模型。

那么，什么是极大似然估计？

首先，我们需要定义一个似然函数作为我们的目标函数，我们需要最大化这个目标函数。假设有n个样本，样本有类别1和0， $p_i$ 是样本属于类别1的概率，那么样本属于类别0的概率为  $1 - p_i$  似然函数的定义为：

$$\prod_{i=1}^n (p_i)^{y_i} (1 - p_i)^{1-y_i}$$

理解上述公式可以分两种情况来考虑，对于一个样本

- 1、假设该样本的类别为1，那么此时概率 $p_i$  大于  $1-p_i$ ，上述公式只剩下 $(p_i)^{y_i}$
- 2、假设该样本的类别为0，那么此时概率 $1-p_i$  大于  $p_i$ ，上述公式只剩下 $(1 - p_i)^{(1-y_i)}$

那么上式怎样才能达到最大呢？显然，逻辑回归模型能决定预测样本属于哪个类，例如样本实际标签为1，那么预测的概率 $p_i$ 的值为1；如果样本实际标签为0，那么预测的概率 $p_i$ 的值为0。如果能准确预测，那么上述似然函数的值为1且为最大值。

我们实际处理过程中不好处理连乘符号，我们对它取对数，可得：

$$C(\tilde{\mathbf{W}}) = -L(\tilde{\mathbf{W}}) = -\sum_{i=1}^n (y_i \log p_i + (1 - y_i) \log(1 - p_i)) \quad \text{交叉熵}$$

此时，我们的目标是最小化上式。

那么如何训练逻辑回归模型呢？

答案是梯度下降：

首先我们需要计算梯度向量，需要对代价函数求关于权值的梯度。

$$\frac{\partial L(\tilde{\mathbf{W}})}{\partial \tilde{\mathbf{W}}} = \sum_{i=1}^n \left[ \left( y_i - \frac{e^{\tilde{\mathbf{W}}^T \tilde{\mathbf{X}}_i}}{1 + e^{\tilde{\mathbf{W}}^T \tilde{\mathbf{X}}_i}} \right) \tilde{\mathbf{X}}_i \right]$$

计算出梯度向量后，每次用梯度向量的反方向来更新权重，即重复下面的操作直至收敛：

$$\begin{aligned} \tilde{\mathbf{W}}_{new}^{(j)} &= \tilde{\mathbf{W}}^{(j)} - \eta \frac{\partial C(\tilde{\mathbf{W}})}{\partial \tilde{\mathbf{W}}^{(j)}} \\ &= \tilde{\mathbf{W}}^{(j)} - \eta \sum_{i=1}^n \left[ \left( \frac{e^{\tilde{\mathbf{W}}^T \tilde{\mathbf{X}}_i}}{1 + e^{\tilde{\mathbf{W}}^T \tilde{\mathbf{X}}_i}} - y_i \right) \tilde{\mathbf{X}}_i^{(j)} \right] \end{aligned}$$